

C 端问答页（RAG 智能问答）

对话体验、可信度、溯源、兜底与访问边界 · 2026-07-12

一、定位与用户

C 端问答页是整个系统「配置 → 验证 → 上线 → 追踪」链路的**唯一对外出口**：管理台里配好的知识库、模型、Prompt、检索参数，最终都收敛到这一个页面为终端用户提供问答服务。它面向两类使用者——真实业务用户（如学员咨询退款、课程问题），以及上线前借同一页面做「测试访问」的运营 / 算法同学。同一套 UI 通过 URL 寻址区分是「正式服务」还是「测试某个配置版本」，避免为测试单独维护一套界面。

设计目标不是做一个更漂亮的 ChatGPT，而是做一个「**可被信任、可被追溯、知道自己边界**」的问答界面。RAG 的价值在于答案有出处，因此本页把「这句话来自哪篇文档」「这个回答有多可信」「没查到时如何诚实兜底」放在与答案本身同等重要的位置。

二、页面结构：三栏布局

左栏 · 会话栏 (280px)

Agent 信息卡、新建 / 切换会话、账号与「管理后台」入口

中栏 · 对话区 (自适应)

顶栏 (Agent 名 + 知识库标签)、消息流、输入区

右栏 · 引用原文 (340px, 可折叠)

本会话命中知识清单 + 选中切片的上下文原文

页面最顶部保留一条**演示用浏览器地址栏**（红黄绿三点 + URL + 「演示切换 URL」快捷链）。这不是产品正式形态，而是 mock 里用来演示「同一页面通过不同 URL 进入不同访问态」的辅助控件，真实部署时该条会被浏览器自身的地址栏取代。中栏顶部右侧的折叠按钮可整体收起 / 展开右栏，为窄屏或专注阅读让出空间。

三、访问模型与上线态

页面用哪一份配置服务，由 URL 决定，共三种寻址模式。这套设计把「上线 / 下线 / 灰度 / 回滚」统一简化为**移动 production 标识**这一个动作——问答页永远解析「当前被打上 production 标识的配置版本」，无需自己感知发布逻辑。

模式	URL 形态	解析到的配置	页面表现
正式服务	codecrush.cn/bot/<id>	该 Agent 的 production 版本	常态，无任何测试提示
测试 · 指定版本	/bot/<id>/v/13	锁定 v13 快照	地址栏「测试访问 · 需登录态」+ 侧栏「测试模式」提示
测试 · 指定标识	/bot/<id>/staging	该命名标识指向的版本	同上，徽标展示标识名与解析到的版本号

测试访问态用两处黄色提示强调「你看到的不是线上正式版本」：地址栏内联「测试访问 · 需登录态」标签（测试链路强制登录，避免未发布配置被匿名访问）；侧栏 Agent 卡下方一条「测试模式 · 正在测<标识/版本>」横幅。二者刻意用暖色而非红色——这是预期内的正常调试行为，不是错误。

未上线占位：当 Agent 没有任何配置版本被打上 production 标识时，正式服务 URL 无法解析，中栏整体替换为居中占位——弱化的 Agent 头像 + 「该 Agent 尚未上线」+ 说明文案（点明是「缺 production 标识」而非配置错误）+ 「去管理平台配置 →」按钮，形成从对外页面直接跳回配置台的闭环。此时不渲染会话与输入区。

四、对象模型

对象	关键字段	说明
会话 Conversation	标题、所属 Agent、更新时间、消息序列	按 Agent 隔离；切 Agent 只看到该 Agent 下的会话
消息 Message	角色（user / bot）、分段内容 parts、可信度、覆盖度、是否兜底	bot 消息按 parts 渲染，文本段与引用角标段交错
引用角标 Citation	序号 n、来源文档、所属知识库、章节、相似度、前 / 中 / 后上下文	正文内可点，联动右栏定位原文
可信度 conf	0-1 浮点	派生出三级标签与百分比，见第五节
覆盖度 cover	full / partial	回答中关键结论是否都有原文支撑
兜底信息 fallback	最高相似度 top、命中阈值 thr、检索范围 scope	仅未命中知识时存在，替代可信度展示

五、消息可信度设计

每条正常回答（非兜底）下方固定展示两枚胶囊标签：**可信度与引用完整度**。这是本页对「AI 可能出错」这一前提最直接的产品化回应——不藏着，而是量化呈现，把是否采信的判断权交还给用户。

1. 可信度三级（由 conf 阈值派生）

区间	标签	颜色	附加提示
conf ≥ 0.85	可信度 高	绿	无
0.70 ≤ conf < 0.85	可信度 中	橙	无
conf < 0.70	可信度 低	红	额外展示黄色「低置信」告警条

标签同时显示百分比（如「可信度 高 · 92%」），颜色贯穿圆点 / 文字 / 描边 / 底色四处保持一致。

2. 引用完整度

与可信度并列的第二枚标签，回答「结论有没有全部落到原文上」这个独立问题：**引用完整**（✓ 绿，「关键结论均有原文支撑」）/ **引用不完整**（! 橙，「部分内容缺少直接来源」）。它与可信度是正交的两个维度——可信度高但引用不完整，意味着模型很确信却有部分内容是自行组织表达的，值得提醒。

3. 低置信告警条

仅当 $conf < 0.70$ 时，在标签下方追加一条黄色告警条：「该回答可信度较低，可能不完全准确。建议点击角标核对原文后再采用。」——把「怎么办」直接写进提示，而不是只丢一个红色标签让用户自己焦虑。

六、引用与溯源

RAG 的核心承诺是「答案可溯源」，本页用**正文角标** ⇄ **右栏原文**的双向联动兑现这一承诺。

- **正文角标**：回答正文里，引用处内联一个蓝色小序号（如 **1**）。角标与文字混排，点击即在右栏定位到对应切片。
- **右栏命中清单**：顶部列出「本会话命中知识 · N 条」，每条为「序号 + 章节名 + 相似度分」的行，当前选中项高亮。这是会话级聚合——把多轮回答引用过的所有切片汇总在一处。
- **右栏原文卡**：选中某条后展示《文档名》+ 所属知识库标签 + 相似度标签 + 更新时间，正文区用「前文（灰）→ 命中段（蓝色左边框高亮 + 章节名）→ 后文（灰）」的方式还原切片在原文中的上下文，让用户判断「这段是不是被断章取义」。
- **空态**：右栏未选中任何角标时，居中提示「点击回答中的 **1** 角标查看命中的知识原文」。

输入区下方常驻一行灰字「回答由 AI 基于知识库生成，点击角标可查看原文出处」，把溯源入口的存在感前置，降低新用户的认知门槛。

七、未命中知识兜底

当检索最高相似度低于命中阈值时，系统不编造答案，而是走「兜底话术」策略回复，并在回答下方用**黄色兜底卡**替代常规可信度标签，逐条摊开「为什么没查到」：

- **超出范围**：问题不属于该 Agent 已接入的知识库主题；
- **相似度过低**：检索最高相似度 X，低于命中阈值 Y（回填真实数值）；
- **检索范围**：说明本次检索覆盖了哪些知识库；
- **已处理**：按「兜底话术」策略回复，未编造知识库外内容。

这套「诚实交代」的设计对内是排查工具（运营一眼看出是知识缺口还是阈值过严），对外是信任建设（宁可说没查到，也不胡编）。

八、反馈机制

每条回答操作栏含三个轻量动作：**复制**（点击后 1.6s 内文案变「已复制」）、**有帮助**（👍，蓝色选中态）、**不准确**（👎，红色选中态）。两个反馈按钮互斥、可再次点击取消。点「不准确」后下方补一行「已记录您的反馈，我们会用于优化该 Agent 的回答质量」——把 C 端的负反馈接到管理台的「知识缺口」沉淀，形成越用越准的数据飞轮的起点。

九、核心交互流程

1. 提问 → 回答

底部输入区多行文本框，**Enter 发送、Shift+Enter 换行**；草稿为空时发送按钮置灰不可点。发送后用户气泡右侧上屏，随即出现三点跳动的 typing 指示，回答返回后替换为带可信度页脚的 bot 气泡。

2. 会话管理

左栏「+ 新建会话」开启空会话；历史列表按更新时间倒序，当前会话高亮（加粗 + 底色）。切换会话即切换中栏消息流与右栏命中清单。会话按 Agent 隔离——通过演示 URL 切到另一个 Agent 时，只展示该 Agent 名下的会话。

3. 右栏折叠

中栏顶栏右侧的切换项可整体收 / 展右栏。收起时对话区占满剩余宽度；点任意角标会自动展开右栏并定位。默认展开态可由页面级配置项 rightPanelDefault 控制。

十、边界条件与异常态

场景	页面处理
Agent 未上线（无 production 标识）	中栏整体占位「尚未上线」+ 跳管理台，不渲染会话与输入
测试访问（版本 / 标识 URL）	地址栏 + 侧栏双重黄色提示，强制登录态
回答未命中知识	兜底卡摊开四条原因，不展示可信度标签
低置信回答（conf<0.7）	红色可信度标签 + 黄色告警条，引导核对原文
未选中任何引用	右栏空态引导语
输入为空 / 仅空白	发送按钮置灰，Enter 不触发发送
长文本 / 多行输入	Shift+Enter 换行，气泡 white-space:pre-wrap 保留换行
登录态失效 / 未登录访问测试 URL	先经登录页；正式服务 URL 是否要登录由 Agent 策略决定

十一、状态与颜色规范

- **主色** #1677ff：用户气泡、角标、链接、主按钮、命中段高亮；
- **绿** #52c41a：高可信、引用完整、「复制成功」；
- **橙 / 黄** #d48806 / #faad14 + #ffffbe 底：中可信、引用不完整、兜底卡、低置信告警、测试模式——统一表达「需注意但非错误」；
- **红** #ff4d4f：低可信、「不准确」选中态——仅用于真正的负向 / 风险信号；
- bot 气泡白底描边 + 极轻阴影，user 气泡蓝底，气泡圆角做非对称处理（贴向头像的一角收窄）区分说话方。

十二、明确不做 / 后续方向

能力	当前取舍
回答流式逐字输出	当前用 typing 指示 + 整段返回；流式为后续体验增强
多模态（图片 / 文件上传提问）	当前聚焦纯文本问答，未接入
追问 / 引导性推荐问题	未预置，避免首屏噪声，留待有真实需求
「不准确」反馈的结构化归因	当前为一键负反馈，细分原因（答错 / 缺来源 / 过时）后续在知识缺口侧补充
网络错误 / 超时的独立异常态	当前 mock 未覆盖，需在后续迭代补充重试 UI

整体判断：本页已把 RAG 问答「可信 · 可溯源 · 知边界」的核心心智做扎实，后续增强集中在**输出体验（流式）、反馈粒度（结构化归因）、异常鲁棒性（网络 / 超时）** 三处，均为在既有框架内的补齐，不改变页面结构与信息架构。